

MAESTRÍA EN CIENCIA DE DATOS
MLEA_M: Machine Learning
Presentación final de curso
2026-1

1 Propósito del trabajo final

El objetivo de este proyecto es desarrollar una aplicación completa de Machine Learning utilizando datos reales seleccionados por el estudiante. El énfasis está en la correcta formulación del problema, el análisis exploratorio, la comparación de múltiples modelos y la interpretación de resultados en un contexto aplicado.

Para ello, los estudiantes podrán utilizar bases de datos provenientes de diversas fuentes. Se recomienda explorar repositorios públicos ampliamente utilizados en la comunidad, como *Kaggle*, repositorios de datos abiertos gubernamentales (por ejemplo, datos abiertos del gobierno colombiano), plataformas académicas y científicas como UCI Machine Learning Repository.

Adicionalmente, los estudiantes pueden trabajar con datos a los que tengan acceso directo, como información empresarial, institucional o proyectos de investigación propios, siempre que cumplan con criterios éticos y de confidencialidad. Se valorará positivamente la selección de datasets que representen problemas reales y relevantes, así como la capacidad de comprender su contexto, limitaciones y potencial de aplicación.

Debe realizar la presentación el **15 de mayo** en el horario de clase de acuerdo a los lineamientos de la presente guía. La nota del curso MLEA_M corresponde a la nota de la presentación.

2 Equipos de trabajo

Puede trabajar individualmente o en pareja de acuerdo a su libre elección.

3 Estructura de la Presentación

En la presentación deben tenerse los siguientes apartados:

1. **Problema y motivación:** En esta sección se debe presentar claramente el problema que se desea resolver, contextualizándolo en una situación real y explicando su relevancia. Es importante indicar si se trata de un problema de clasificación, regresión o clustering, así como justificar por qué es importante abordarlo y qué tipo de decisiones o procesos podrían mejorarse mediante el uso de machine learning.
2. **Datos:** Se debe describir la fuente de los datos utilizados, indicando si provienen de plataformas públicas, datos abiertos o fuentes propias. Además, se debe mencionar el número de observaciones y variables, así como explicar las variables más relevantes para el problema. También es fundamental identificar posibles problemas en los datos, como valores faltantes, desbalance de clases o inconsistencias.
3. **EDA (Análisis Exploratorio de Datos):** En esta parte se deben presentar los resultados del análisis exploratorio, incluyendo estadísticas descriptivas y visualizaciones relevantes. Se espera que el estudiante identifique patrones, relaciones entre variables y posibles anomalías, generando insights que orienten el proceso de modelado. Se pueden utilizar modelos no supervisados para la exploración.
4. **Modelos:** Se deben describir los modelos de machine learning implementados, asegurando el uso de al menos tres enfoques diferentes. Para cada modelo, se debe justificar su elección y explicar de manera conceptual su funcionamiento, destacando sus ventajas y limitaciones en el contexto del problema.

5. **Comparación de métricas:** En esta sección se deben presentar las métricas utilizadas para evaluar los modelos, tales como accuracy, precision, recall, F1-score, matriz de confusión y métricas de modelos de regresión, según sea el caso. Es importante incluir una comparación clara entre los modelos, preferiblemente mediante tablas o gráficos, e identificar cuál presenta el mejor desempeño, acompañando esto con una discusión de los resultados obtenidos.
6. **Aplicación:** Aquí se debe explicar cómo el modelo desarrollado podría utilizarse en un contexto real. Se debe indicar quién sería el usuario final, qué decisiones apoyaría el modelo y cuál sería su impacto potencial. También es importante mencionar posibles limitaciones para su implementación en la práctica.
7. **Conclusiones.** Finalmente, se deben presentar los principales hallazgos del proyecto, indicando cuál fue el mejor modelo y justificando su elección. Además, se deben discutir las limitaciones del trabajo realizado y proponer posibles mejoras o líneas de trabajo futuro.

4 Condiciones de Presentación

- Todos los integrantes deben participar
- Tiempo máximo: 12 minutos
- Mostrar código haciendo uso de Notebooks (jupyter) e incluir celdas markdown para una mejor claridad.
- Justificar decisiones tomadas
- En caso de no poder sustentar el 15 de mayo, deberá enviar un video de su presentación a más tardar el 16 de mayo. En este caso, sólo se acepta el envío por MS Teams en la tarea correspondiente.
- Los grupos de exposición serán seleccionados al azar, así que deben estar preparados para el 15 de mayo.

5 Rúbrica de Evaluación (50 puntos)

Sección evaluada	Puntos	Descripción
Problema y motivación	4	Planteamiento claro del problema en contexto real, relevancia bien justificada y correcta identificación del tipo de problema (clasificación, regresión, clustering).
Datos	4	Descripción adecuada de la fuente, variables y tamaño del dataset. Identificación de problemas como valores faltantes, desbalance o inconsistencias.
EDA (Análisis Exploratorio)	8	Análisis exploratorio sólido con visualizaciones relevantes, identificación de patrones y generación de insights que apoyen el modelado.
Modelos	14	Implementación de múltiples modelos (mínimo 3, ideal 4 o más), correcta justificación de su uso y comparación estructurada entre ellos. Se valora la diversidad de enfoques.
Métricas comparativas	6	Uso adecuado de múltiples métricas (accuracy, precision, recall, F1 u otras según el problema) y comparación clara entre modelos que permita seleccionar el mejor.
Hiperparámetros	4	Aplicación de técnicas de optimización (GridSearch, RandomSearch u otras) y justificación de la selección de parámetros.
Aplicación	4	Explicación clara de cómo el modelo se utiliza en un contexto real, incluyendo impacto, usuarios y toma de decisiones.
Código	3	Código organizado, documentado, reproducible y coherente con el análisis presentado.
Presentación	3	Claridad en la exposición, estructura lógica, uso adecuado del tiempo (12 minutos) y participación de todos los integrantes.
Total	50	

6 Recomendaciones Finales

- No limitarse a un solo modelo
- Interpretar resultados (no solo reportarlos)
- Relacionar el modelo con una aplicación real
- Mantener claridad en las diapositivas